

UNIVERSIDADE DE MARÍLIA - POLO ASSIS SP

Curso: Superior de Tecnologia em Ciência de Dados

Disciplina: Projeto Integrador Extensionista CD 1

Módulo: M2.26

Discente: Gabriel Marchetti Motta

Atividade de Estudo 2 (AE2) - Desenho Técnico da Solução.

1. Dicionário de Dados (Versão 1)

O projeto utilizará um subconjunto dos microdados do ENEM, filtrado especificamente para a cidade de Assis-SP. As colunas selecionadas para responder às perguntas analíticas estão descritas abaixo:

Campo (Coluna)	Tipo Esperado	Descrição	Origem	Regra de Preenchimento / Validação
NU_INSCRICAO	Numérico (BigInt)	Número de inscrição único do candidato.	INEP (Microdados)	Chave primária. Não pode ser nulo. Não pode ter duplicidade.
NO_MUNICIPIO_PROVA	Texto (String)	Nome da cidade onde o aluno fez a prova.	INEP (Microdados)	Não pode ser nulo. Deve ser obrigatoriamente "Assis".
SG_UF_PROVA	Texto (String)	Sigla do Estado.	INEP (Microdados)	Deve ser obrigatoriamente "SP".
TP_ESCOLA	Numérico (Int)	Tipo de escola do Ensino Médio (2 = Pública, 3 = Privada).	INEP (Microdados)	Valores permitidos: apenas 2 ou 3. (Alunos que não responderam = 1 serão excluídos).

NU_NOTA_MT	Numérico (Float)	Nota da prova de Matemática .	INEP (Microdados)	Não pode ser nulo. Valor deve estar entre 0.0 e 1000.0.
NU_NOTA_REDACAO	Numérico (Float)	Nota da prova de Redação.	INEP (Microdados)	Não pode ser nulo. Valor deve estar entre 0.0 e 1000.0.

2. Modelo Lógico (Versão 1)

Devido à natureza da fonte de dados (arquivo CSV de microdados) e ao escopo focado do projeto, optou-se por uma arquitetura de Tabela Única (Flat Table), eliminando a necessidade de cruzamentos (JOINS) complexos que poderiam comprometer a performance, o que é ideal para este MVP (Produto Mínimo Viável).

Abaixo a descrição tabular do modelo:

- **Nome da Tabela:** enem_assis_notas
- **Chave Primária (PK):** NU_INSCRICAO (Garante que cada aluno apareça apenas uma vez na tabela).
- **Chaves Estrangeiras (FK):** Não há. O modelo é desnormalizado (tabela única) para facilitar a leitura do Dashboard no Power BI.
- **Relacionamentos:** Não se aplica. Todos os dados necessários para o Power BI já estarão contidos nesta tabela tratada.

3. Plano de Qualidade de Dados

Para garantir que os dados do INEP não tragam distorções para o nosso painel, o script Python de ETL realizará, no mínimo, as seguintes 6 checagens de qualidade:

1. **Checagem de Duplicidade:** Verificar se a chave primária (NU_INSCRICAO) possui valores duplicados. Se houver, manter apenas a primeira ocorrência.

2. **Checagem de Domínio de Valores (Localidade):** Garantir que a coluna NO_MUNICIPIO_PROVA contenha exclusivamente a string "Assis". Linhas diferentes disso serão excluídas.
3. **Checagem de Domínio de Valores (Escola):** A coluna TP_ESCOLA deve conter apenas os valores 2 (Pública) ou 3 (Privada). Candidatos que não informaram (valor 1) serão excluídos da base.
4. **Checagem de Nulos em Campos Obrigatórios (Matemática):** Remover todas as linhas (candidatos) onde a nota de Matemática (NU_NOTA_MT) for nula ou vazia (candidatos ausentes).
5. **Checagem de Nulos em Campos Obrigatórios (Redação):** Remover todas as linhas onde a nota de Redação (NU_NOTA_REDACAO) for nula ou vazia.
6. **Checagem de Faixa Plausível (Outliers/Erros):** Garantir que todas as notas (NU_NOTA_MT e NU_NOTA_REDACAO) estejam estritamente dentro da faixa de 0.0 a 1000.0. Valores fora dessa faixa indicam erro na origem e serão removidos.

4. Plano de Análise (EDA) e Produto Final

Gráfico e tabelas necessários:

- Gráfico de Barras 1:
- Nota Média de Matemática (Pública vs. Privada).
- Gráfico de Barras 2: Nota Média de Redação (Pública vs. Privada). Cartões de KPI: Quantidade total de alunos analisados e a diferença percentual da defasagem.

Insights esperados a responder:

- Qual é a exata diferença (em pontos e em percentual) entre um aluno da rede pública e um da rede privada de Assis no ENEM?
- O abismo educacional na cidade é maior nas ciências exatas (Matemática) ou na escrita (Redação)?

Esboço do Dashboard (Wireframe Descritivo):

O painel no Power BI será construído em uma única página, focado em simplicidade e leitura rápida. O layout será dividido nas seguintes áreas:

- **Área Superior (Cabeçalho):** Conterá o título do projeto ("Raio-X do ENEM - Assis/SP") no lado esquerdo, e um Filtro de Ano no lado direito.
- **Área Central (Cartões de KPI):** Conterá 3 cartões retangulares lado a lado. O primeiro mostrará o Total de Alunos analisados. O segundo mostrará a Defasagem Percentual em Matemática. O terceiro mostrará a Defasagem Percentual em Redação.
- **Área Inferior (Gráficos):** Conterá 2 gráficos de colunas grandes, dispostos lado a lado. O gráfico da esquerda comparará as notas de Matemática (barra da rede pública vs. barra da rede privada). O gráfico da direita fará a mesma comparação para a disciplina de Redação.

5. Atualização do GitHub

Estrutura de Pastas Definida: Para organização do projeto final, o repositório seguirá a seguinte hierarquia:

- /docs: (Documentações do projeto, arquivos da AE1 e AE2).
- /data: (Onde ficará o arquivo CSV final, já tratado, com os alunos de Assis).
- /notebooks: (Onde ficará o código Python/Jupyter de ETL e EDA).
- /dashboard: (Onde ficará o arquivo .pbix do Power BI).

Issues / Tarefas criadas para execução futura: As seguintes 6 tarefas (issues) devem guiar o desenvolvimento futuro do projeto:

1. **Tarefa 1:** Fazer download dos microdados originais do ENEM no site do INEP.
2. **Tarefa 2:** Criar script Python para carregar o CSV e filtrar município de Assis-SP.

3. **Tarefa 3:** Aplicar as 6 regras de qualidade de dados (ETL) no Python.
4. **Tarefa 4:** Exportar o arquivo CSV limpo ("enem_assis_tratado.csv").
5. **Tarefa 5:** Importar o CSV limpo no Power BI.
6. **Tarefa 6:** Construir os gráficos propostos no Wireframe e publicar o painel.

Link do Repositório GitHub: <https://github.com/gabmchetti/projeto-enem-assis>